

Da Dati Aperti a Nota Tecnica: Un Flusso di Lavoro Riproducibile in VSCode per l'Analisi dei Segnali Precursori ai Campi Flegrei

Identificazione e Accesso alle Fonti Dati Aperti Ufficiali INGV

La definizione di una strategia efficace ed efficiente per l'acquisizione dei dati fondamentali per l'analisi dei segnali precursori nell'area dei Campi Flegrei parte da una precisa identificazione delle fonti ufficiali e aperte, esclusivamente quelle gestite dall'Istituto Nazionale di Geofisica e Vulcanologia (INGV). Questo vincolo non solo garantisce l'autenticità e la qualità dei dataset, ma si allinea con le migliori pratiche della scienza dei dati aperti, essenziali per la produzione di un documento tecnico destinato a un osservatorio scientifico quale l'INGV-Osservatorio Vesuviano. La strategia di recupero deve essere basata su un approccio sistematico, che mappi ogni tipo di dato richiesto a una specifica infrastruttura di dati INGV, descrivendone le modalità di accesso, il formato tipico e le caratteristiche operative.

Per quanto riguarda i dati geodetici, la priorità è la serie temporale relativa alla stazione BEPOS, rientrante nella rete GNSS RITE (Reti di Tracciamento Eterogenee) ³³. Sebbene la rete RITE sia spesso associata al monitoraggio del Vesuvio, i suoi principi e le sue architetture di dati sono applicabili anche all'area dei Campi Flegrei, dove la deformazione crostale è un parametro critico di studio ^{24 34}. La fonte primaria per l'accesso a questi dati è il Portale dei Dati Aperti dell'INGV ⁷. Questo portale funge da hub centrale per la distribuzione di una vasta gamma di prodotti geofisici, inclusi i dati di posizionamento satellitare. Le serie temporali di coordinate precise, solitamente fornite in formato CSV con componenti nord, est e up (N/E/U), rappresentano il formato ideale per un'elaborazione automatizzata tramite script in R o Python. La procedura di accesso prevederà una navigazione diretta nel portale, l'identificazione del dataset specifico "GNSS RITE" o correlato, e il download programmabile dei dati relativi al periodo di interesse, in questo caso, il periodo antecedente e successivo agli eventi del 17-18 febbraio 2026. È importante notare che, sebbene i dati siano pubblici, potrebbero essere

organizzati in sotto-cartelle o contenuti in pacchetti compressi, richiedendo uno scripting leggermente sofisticato per l'estrazione automatica. La letteratura scientifica conferma l'utilizzo di dati GNSS per studiare le variazioni a lungo termine della caldera dei Campi Flegrei, sottolineando la pertinenza di questa fonte [24](#).

Il secondo pilastro della strategia riguarda i dati sismici. L'obiettivo è ottenere il catalogo degli eventi sismici specifici per il 17 e 18 febbraio 2026. La fonte primaria per tale scopo è il portale GOSSIP (GOnnet-based Seismicity data Processing System), menzionato esplicitamente come strumento per l'estrazione di eventi sismici con parametri specifici, come i tempi di interevento inferiori a 30 secondi [27](#). GOSSIP è uno strumento operativo dell'INGV concepito per la rapida analisi e la distribuzione dei dati sismici, rendendolo lo strumento ideale per la preparazione di una Nota Tecnica urgente. Oltre a GOSSIP, l'INGV fornisce accesso ai cataloghi sismici operativi attraverso il portale "INGV Earthquake List" [14](#). Questo portale permette di interrogare i dati storici e recenti, filtrandoli per località, intervallo di tempo e magnitudo. Per l'analisi statistica avanzata prevista, come l'analisi di sopravvivenza (Weibull) e i modelli di Hawkes, è necessario non solo il catalogo degli eventi, ma anche la derivazione esplicita dei tempi di interevento (IET). Questo passaggio può essere integrato nello script di recupero dati, che una volta scaricati i parametri base (coordinate, magnitudo, tempo), calcola automaticamente gli IET ordinandoli temporalmente. È altresì utile considerare l'esistenza della task force SISMO (Seismic Emergency Mobile Network), attivata per eventi sismici significativi ($M \geq 5.0$) o sequenze prolungate [13](#). Se l'evento del febbraio 2026 fosse stato sufficientemente intenso da giustificare l'attivazione, potrebbero essere disponibili dati aggiuntivi da reti temporanee. Tali dati vengono resi pubblici senza restrizioni tramite l'archivio europeo EIDA (European Integrated Data Archive) e sono citabili tramite un DOI (Digital Object Identifier) permanente, costituendo una fonte secondaria potenzialmente ricca ma che richiederebbe un processo di recupero più complesso, probabilmente utilizzando librerie come ObsPy in Python per interrogare l'API di EIDA [14](#).

Infine, per i dati geochimici, la ricerca si concentra sulla serie temporale del rapporto $\text{CO}_2/\text{H}_2\text{O}$ raccolta presso le stazioni di Pisciarelli e Solfatara. Questa categoria di dati ha fonti estremamente ben definite e riconoscibili nella letteratura scientifica dedicata ai Campi Flegrei. Numerose pubblicazioni menzionano esplicitamente l'attività di sorveglianza geochimica in queste aree specifiche [1](#) [2](#) [6](#) [17](#). Ad esempio, studi recenti discutono delle serie temporali del flusso di CO_2 misurate da una stazione automatica (FLXOV3) al sito di Pisciarelli [1](#), mentre altri indagano i cronogrammi del rapporto molare $\text{H}_2\text{O}/\text{CO}_2$ a Solfatara e Pisciarelli [6](#). L'INGV stesso promuove e gestisce un sistema di monitoraggio multiparametrico che include attivamente la sorveglianza

geochimica dei Campi Flegrei e del Vesuvio [8](#) [9](#) . Pertanto, i dati geochimici dovrebbero essere recuperabili direttamente dal portale dati INGV o tramite database specializzati interni all'INGV. Le fonti indicano la disponibilità di dati di flusso di CO₂ a lungo termine a Solfatara [3](#) e di temperature e pressioni idrotermali a Solfatara e Pisciarelli [2](#) . Il recupero di questi dati potrebbe richiedere un accesso a un repository di dati scientifici o, in alcuni casi, un contatto diretto con i gruppi di ricerca responsabili della raccolta dati. I formati tipici includeranno serie temporali con valori giornalieri o orari del rapporto CO₂/H₂O, unità di misura (es. rapporto molare, ppm) e informazioni sulle tecniche di campionamento. La frequenza temporale di questi dati è un parametro critico, poiché deve essere compatibile con quella dei dati geodetici e sismici per consentire un'analisi integrata e coerente nel tempo.

Tipo di Dato	Fonte Primaria Ufficiale INGV	Strumento di Accesso	Formato Tipico	Note Operative
Geodetico (GNSS)	Portale Open Data INGV	Download manuale o script web scraping/API	CSV (Coordinate U/E/N) 7	Dati relativi alla stazione BEPOS e/o rete RITE. Verificare la copertura temporale.
Sismico	Portale GOSSIP / Catalogo Sismico INGV 14	Interrogazione online via GOSSIP; API del portale INGV Earthquake List	Lista eventi (CSV/JSON); Tempi di Interevento (IET) calcolati	Recuperare evento #51675 e #51678 27 . Calcolare gli IET per l'analisi Weibull/Hawkes.
Geochimico (CO ₂ /H ₂ O)	Sistema di Monitoraggio Multiparametrico INGV 9	Portale dati INGV, database interni, o contatto con ricercatori OV 1 6	Serie temporale (giornaliera/oraria)	Dati da stazioni Pisciarelli e Solfatara. Verificare unità di misura e frequenza temporale.

In sintesi, la prima fase strategica consiste nel tradurre la necessità di dati in un piano d'azione concreto, mappando ogni tipo di informazione desiderata a un punto di accesso digitale specifico e verificato. Questa mappatura non è solo un elenco di link, ma una guida metodologica che anticipa i formati, le potenziali difficoltà e le procedure di recupero, stabilendo così una base solida per la successiva automazione e validazione.

Architettura del Progetto e Automazione del Flusso di Lavoro in VSCode

Una volta identificate le fonti dati, il passo successivo cruciale per garantire efficienza ed efficacia è la progettazione di un'architettura di progetto robusta e replicabile, ottimizzata per l'ambiente di sviluppo integrato VSCode. Questo approccio trasforma il processo di analisi da una serie di operazioni disperse in una pipeline software ben definita, dove ogni componente — codice, dati, configurazione e documentazione — ha il suo posto

preciso. L'architettura delineata non solo facilita il lavoro quotidiano, ma soddisfa implicitamente i requisiti di riproducibilità e trasparenza richiesti per un prodotto istituzionale destinato all'INGV. L'uso di VSCode viene enfatizzato perché offre un insieme integrato di strumenti per la gestione del codice, la visualizzazione dei dati e l'automazione dei processi, rendendolo l'ambiente ideale per questa tipologia di lavoro scientifico.

La struttura del progetto deve essere gerarchica e logica, distinguendo chiaramente tra dati grezzi, dati elaborati, codice sorgente, output generati e file di configurazione. Una struttura eccellente, conforme alle linee guida metodologiche [33](#), è la seguente:

- ``data/raw/``: Questa cartella contiene i dataset grezzi appena scaricati dalle fonti INGV. È fondamentale che i file inseriti qui non subiscano mai modifiche manuali o di codice. Questo assicura la preservazione dell'integrità dei dati originali, un prerequisito per qualsiasi forma di verifica scientifica.
- ``data/processed/``: Contiene i dataset puliti, filtrati, aggregati e pronti per l'analisi statistica avanzata. Gli script di preprocessing trasformano i file da ``raw/`` e li salvano qui, creando una linea di demarcazione netta tra la materia prima e il materiale lavorato.
- ``scripts/``: All'interno di questa directory risiedono tutti gli script automatizzati, scritti in R e Python, che orchestrano l'intero flusso di lavoro. Sarà presente uno script per il recupero dei dati GNSS, uno per quello sismico e uno per quello geochimico, oltre a script più specifici per ogni fase dell'analisi (es. ``gnss_analysis.R``, ``seismic_hawkes.py``).
- ``notebook/``: Questa cartella ospita il report interattivo, tipicamente un file ``Rmd`` (per RMarkdown) o un notebook Jupyter (``ipynb``). Questo documento è il cuore dell'output narrativo, collegando i risultati grafici e tabellari alle analisi statistiche sottostanti, e permettendo una ricostruzione passo-passo del ragionamento scientifico.
- ``reports/fig/``: I grafici finali, generati ad alta risoluzione (300 dpi), verranno salvati qui per essere poi inseriti nella Nota Tecnica finale (``Flegrei_Alert_2026.pdf``).
- File top-level: Al livello superiore della cartella del progetto, saranno presenti i file di configurazione essenziali: ``gitignore`` per il controllo di versione, ``README.md`` per la documentazione generale del progetto, ``metadata.yaml`` per i metadati FAIR, ``Dockerfile`` per la containerizzazione e la checklist operativa ``CHECKLIST.md``.

L'efficienza operativa deriva dall'automazione di ogni singolo passaggio, specialmente il recupero dei dati. Invece di scaricare i file manualmente, si svilupperanno script specifici

per ogni fonte dati. Per i dati GNSS, uno script Python potrà utilizzare la libreria `requests` per fare un download HTTP del file CSV dal Portale Open Data INGV [7](#), salvandolo correttamente nella cartella `data/raw/`. Per i dati sismici, la libreria `obspy` è lo strumento standard per interrogare le API dei servizi FDSN (International Federation of Digital Seismograph Networks), come quello gestito dall'INGV [14](#). Uno script in Python può essere configurato per richiedere i dati per un'area geografica specifica (i Campi Flegrei) e un intervallo di tempo preciso (17-18 febbraio 2026), ricevendo i dati in formati standard come MiniSEED o, dopo ulteriore processing, in CSV [14](#). Per i dati geochimici, il recupero potrebbe richiedere uno script personalizzato che gestisca il login o l'interfacciamento con un database web, ma l'obiettivo rimane lo stesso: automatizzare il download e il salvataggio in `data/raw/`.

VSCode diventa lo strumento centrale che integra e semplifica questo flusso di lavoro. Installando le estensioni appropriate, l'ambiente di lavoro diventa estremamente potente:

- **GitLens**: Estende la funzionalità nativa di Git in VSCode, permettendo di visualizzare l'history di ogni singola riga di codice, chi ha modificato cosa e quando. Questo è fondamentale per la tracciabilità e la revisione paritaria [27](#).
- **R (R by Posit) e Python (ms-python)**: Forniscono supporto intelligente per il coding, debug, e l'esecuzione di blocchi di codice direttamente nell'editor.
- **Docker**: Permette di gestire e costruire immagini Docker direttamente dalla sidebar di VSCode, rendendo l'ambiente di analisi completamente isolato e riproducibile [13](#).
- **Markdown All in One**: Migliora l'editing dei file Markdown, come `README.md` e `CHECKLIST.md`, consentendo di spuntare le caselle di controllo e visualizzare anteprime live.
- **YAML**: Offre completamento automatico e convalida per i file `metadata.yaml`, evitando errori di sintassi.

Un'altra potente funzionalità di VSCode è `tasks.json`, un file di configurazione che permette di definire e lanciare comandi shell personalizzati direttamente dall'IDE. Si può definire un "task" per "Costruire l'immagine Docker", un altro per "Compilare il report RMarkdown" e persino un task "Esegui Tutta l'Analisi" che avvia la pipeline completa. Questo significa che con un'unica azione (es. premendo `Ctrl+Shift+P` e selezionando il task), è possibile eseguire una sequenza complessa di comandi (build, run script, knit report), massimizzando l'efficienza e minimizzando la possibilità di errori umani durante la preparazione dei dati. Questa architettura e automazione trasformano il lavoro da un insieme di clic e operazioni manuali a una serie di chiamate a funzioni ben definite, rendendo il processo non solo più veloce, ma anche più affidabile e facilmente documentabile.

Metodologie di Validazione dei Dati e Gestione dei Metadati FAIR

Una volta che i dati sono stati recuperati e organizzati secondo l'architettura del progetto, la fase successiva, di fondamentale importanza per l'efficacia scientifica, è la loro validazione e la gestione sistematica dei metadati. Questo passaggio garantisce che i risultati dell'analisi siano basati su dati affidabili, tracciabili e interpretabili, rispondendo ai rigorosi standard richiesti da un'organizzazione scientifica come l'INGV. La strategia si articola in due aree principali: la validazione dell'integrità dei dati tramite meccanismi crittografici come i checksum, e la riorganizzazione dei metadati secondo i principi FAIR (Findable, Accessible, Interoperable, Reusable).

La validazione dell'integrità dei dati è il primo anello della catena di fiducia. Quando un file di dati viene scaricato da una fonte remota, è impossibile sapere con certezza se il file locale sia identico a quello originale, potendo essere stato alterato durante il download o essere intrinsecamente corrotto. Per mitigare questo rischio, ogni file scaricato, sia esso un dataset GNSS, un catalogo sismico o una serie temporale geochimica, deve essere accompagnato da un valore di checksum. Lo SHA-256 è uno standard moderno e robusto per questo scopo. Nella pratica, ogni volta che uno script di recupero dati scarica un nuovo file nella cartella `data/raw/`, esso dovrà eseguire automaticamente un calcolo SHA-256 su quel file. Questo valore univoco viene poi registrato in un file di metadati centrale, `metadata.yaml`. Questo file agisce come un registro affidabile, associando ogni file grezzo al suo checksum originale. In futuro, chiunque voglia verificare l'integrità di un file può semplicemente ricalcolarne il checksum e confrontarlo con il valore registrato in `metadata.yaml`. Questa procedura, sebbene apparentemente semplice, è un elemento chiave per la riproducibilità e l'affidabilità del lavoro scientifico, poiché elimina l'incertezza sulla provenienza e sull'integrità dei dati di input [10](#) [20](#).

Parallelamente alla validazione dell'integrità, la gestione dei metadati secondo i principi FAIR è cruciale per garantire che i dati siano non solo utilizzabili per l'analisi corrente, ma anche riutilizzabili e comprensibili nel futuro. I principi FAIR forniscono un quadro concettuale per migliorare la gestione delle risorse digitali [20](#). Applicati a questo progetto, essi si traducono in:

- **Findable (Trovabile):** Ogni dataset deve avere un identificatore univoco e persistente. Nel contesto di questo progetto, l'identificatore sarà il percorso del file all'interno della struttura del progetto (es. ``data/raw/gnss.csv``). A livello più ampio, quando il dataset verrà caricato su Zenodo, otterrà un DOI (Digital Object Identifier) che ne farà un oggetto trovabile sul Web [13](#).

- **Accessible (Accessibile):** I metadati devono essere descrittivi abbastanza da poter essere trovati da umani e sistemi. Il file `metadata.yaml` è il fulcro di questa caratteristica. Deve contenere informazioni dettagliate su ogni dataset: titolo, descrizione, parole chiave, autore, anno, e soprattutto, la licenza di uso. La licenza CC-BY-4.0 è una scelta standard e appropriata per i dati aperti, che consente il riutilizzo purché l'autore originale venga attribuito [20](#).
- **Interoperable (Interoperabile):** I dati e i metadati devono essere in un formato basato su standard aperti, come CSV per i dati tabulari e YAML per i metadati. Inoltre, le unità di misura devono essere esplicite e conformi a standard internazionali (es. metri per le coordinate GNSS, secondi per i tempi sismici, rapporto molare per i gas). Questo assicura che i diversi dataset (geodetico, sismico, geochimico) possano essere combinati e analizzati insieme senza ambiguità [21](#).
- **Reusable (Riutilizzabile):** Affinché un dato sia riutilizzabile, è necessario comprendere pienamente il suo contesto. Il file `metadata.yaml` deve quindi includere informazioni cruciali come la procedura di raccolta dati, la precisione e l'accuratezza, e qualsiasi nota sull'eventuale trattamento dei dati (es. rimozione di outlier). Registrare il checksum è un altro passo fondamentale per la riutilizzabilità, poiché permette a un altro ricercatore di riprodurre esattamente lo stesso set di dati usato per l'analisi originale.

La tabella seguente illustra come il file `metadata.yaml` potrebbe essere strutturato per un singolo dataset:

```
dataset_id: gnss_bepos_flegrei_feb2026
title: "Time Series of GNSS Position at BEPOS Station"
description: "Daily position time series (U/E/N components) from the BEPOS"
doi: "" # Sarà popolato da Zenodo
license: "CC-BY-4.0"
author:
  name: "Pietro [Your Name]"
  affiliation: "[Your Institution]"
created: "2026-04-27"
version: "1.0.0"
source:
  url: "https://data.ingv.it/dataset/1085"
  description: "INGV Open Data Portal - GNSS RITE dataset"
  retrieval_date: "2026-04-25"
checksum:
  algorithm: "SHA-256"
  value: "abcdef123456..." # Valore calcolato automaticamente dallo scri
```

variables:

- name: "time_utc"
type: "datetime"
unit: "ISO 8601"
description: "Universal Time Coordinate of the measurement"
- name: "position_up"
type: "float"
unit: "mm"
description: "Vertical position component relative to a reference frame"
- name: "position_east"
type: "float"
unit: "mm"
description: "East position component relative to a reference frame"
- name: "position_north"
type: "float"
unit: "mm"
description: "North position component relative to a reference frame"

Questo approccio sistematico alla validazione e alla gestione dei metadati eleva il livello di professionalità del lavoro, dimostrando un impegno per la trasparenza e la rigorosa metodologia scientifica. Garantisce che la Nota Tecnica sia basata su un fondamento solido e che l'intero processo sia documentato in modo tale da poter resistere a un'attenta revisione da parte di pari esperti.

Implementazione della Riproducibilità Scientifica tramite Container e Controllo di Versione

Garantire la riproducibilità a lungo termine è un requisito implicito ma fondamentale per un'analisi scientifica destinata a un osservatorio vulcanologico. La capacità di un altro ricercatore, o addirittura lo stesso autore dopo mesi o anni, di riprodurre esattamente i risultati partendo dal codice e dai dati originali è il sigillo della validità di un'indagine. Per raggiungere questo obiettivo, la strategia proposta integra due tecnologie moderne e collaudate: la containerizzazione con Docker e il controllo di versione con Git. Questi strumenti, quando utilizzati sinergicamente, creano un ambiente di lavoro isolato, documentato e trasparente, risolvendo il problema classico "sulla mia macchina funziona" e fornendo una prova tangibile della solidità del lavoro svolto.

Il primo passo per la riproducibilità è isolare l'ambiente di esecuzione. Le analisi in R e Python dipendono da una vasta gamma di librerie e pacchetti (`tidyverse`, `survival`, `lmtest`, `tick`, `obspy`, ecc.), ognuno dei quali ha le proprie dipendenze software e versioni specifiche. L'installazione di questi pacchetti può variare da un sistema operativo all'altro e da un utente all'altro, portando a risultati differenti anche con lo stesso codice. Docker risolve questo problema creando un "container" isolato, una sorta di micro-virtual machine leggera che contiene tutto ciò di cui l'analisi ha bisogno: un sistema operativo minimo, la versione esatta di R (es. 4.4) e Python (es. 3.12), e l'elenco preciso di tutti i pacchetti installati. La definizione di questo ambiente viene codificata in un file di testo chiamato `Dockerfile`. Questo file è esso stesso parte del progetto, versionato con Git. Il `Dockerfile` per questo progetto specificherà la `FROM` image base (es. `rocker/tidyverse:4.4.0` per R o `continuumio/miniconda3` per Python), installerà i pacchetti R e Python necessari tramite i rispettivi gestori di pacchetti (`install.packages()` e `conda install`), e configurerà le variabili di ambiente. La creazione di un'immagine Docker a partire da questo file (`docker build -t flegrei-alert .`) produce un ambiente eseguibile e replicabile ovunque Docker sia installato. Questo garantisce che l'analisi sia condotta in un contesto computazionale perfettamente definito e privo di ambiguità [13](#).

Il secondo pilastro della riproducibilità è il controllo di versione, realizzato tramite Git. Git non è solo uno strumento per salvare copie del proprio lavoro; è un sistema di tracciamento delle modifiche che registra ogni cambiamento al codice, ai metadati e alla documentazione, insieme a un messaggio esplicativo e a un timestamp. Integrato con un servizio hosting come GitHub o GitLab, crea un repository remoto e sicuro, che agisce come una fonte unica e definitiva della verità sul progetto. La struttura del progetto descritta precedentemente è ideale per Git: il codice negli script e i dati processati leggeri nelle cartelle `processed/` possono essere committati regolarmente. I dati grezzi, che spesso sono molto grandi, dovrebbero essere esclusi dal controllo di versione tramite il file `.gitignore`. Se i dati grezzi sono troppo voluminosi per essere archiviati anche su piattaforme che offrono opzioni per grandi file come Git LFS (Large File Storage), la pratica migliore è mantenerli localmente fino al momento dell'archiviazione finale su un deposito dati a lungo termine. GitLens, un'estensione per VSCode, rende questa tracciabilità visivamente intuitiva, mostrando l'history delle modifiche direttamente nel codice [27](#).

La vera potenza della combinazione Docker e Git emerge quando si considera l'archiviazione a lungo termine. Prima dell'invio della Nota Tecnica all'INGV, l'intero repository Git, che contiene il codice, i metadati e la documentazione, dovrebbe essere caricato su un deposito dati come Zenodo [13](#). Zenodo è un servizio di archiviazione dati che integra nativamente con GitHub/GitLab, permettendo di creare una nuova versione

del deposito ogni volta che viene effettuato un commit in un branch specifico del repository. In cambio di questo caricamento, Zenodo assegna al pacchetto di dati un DOI (Digital Object Identifier) permanente e citabile. Questo DOI diventa il marchio di fabbrica della riproducibilità: qualunque persona interessata ai risultati può accedere al DOI, scaricare l'intero pacchetto (codice, dati processati, metadati) e, utilizzando il `Dockerfile` incluso, costruire l'ambiente esatto in cui l'analisi è stata condotta e rieseguire l'analisi stessa per verificare i risultati. Questo processo non solo soddisfa pienamente il requisito di riproducibilità, ma eleva anche il lavoro a un livello di trasparenza e professionalità che è il standard per la ricerca scientifica moderna. La Nota Tecnica inviata all'INGV dovrebbe quindi includere un riferimento a questo DOI, trasformando un documento statico in un punto di accesso a un ecosistema di ricerca dinamico e verificabile.

Strumento	Ruolo nella Riproducibilità	Funzionalità Chiave
Docker	Isolamento dell'Ambiente di Esecuzione	Crea un ambiente computazionale eseguibile e replicabile ovunque. Definito tramite <code>Dockerfile</code> 13 .
Git	Controllo di Versione del Codice e Documentazione	Registra ogni modifica al codice e ai metadati, creando un registro auditabile e una fonte unica della verità.
Zenodo	Archiviazione a Lungo Termine e Citabilità	Archivia l'intero repository Git, assegnando un DOI permanente e citabile al lavoro, rendendolo accessibile e verificabile a vita.
<code>.gitignore</code>	Gestione dei File Ignorati	Esclude file non versionabili (dati grezzi, cache, ambienti virtuali) dal repository Git per mantenere la sua leggerezza e centralità.

In conclusione, l'implementazione di questa triade tecnologica (Docker, Git, Zenodo) non è un onere burocratico, ma un investimento strategico che garantisce che il valore scientifico della Nota Tecnica non si esaurisca con la sua lettura, ma continui a essere un bene condivisibile, verificabile e costruttivo per la comunità scientifica.

Checklist Operativa e Pianificazione dello Svolgimento Analitico

Per tradurre la strategia teorica in un'azione concreta ed efficace, è indispensabile disporre di una pianificazione dettagliata e di una checklist operativa. Questo strumento pratica guida l'utente attraverso ogni fase del progetto, dalla creazione dell'ambiente di lavoro fino alla preparazione dei dati finali per l'analisi, assicurando che nessun passaggio critico venga omissso. La checklist è stata progettata per essere utilizzata direttamente in VSCode, sfruttando le funzionalità dei file Markdown per spuntare le attività completate

27. La pianificazione è suddivisa in fasi cronologiche, riflettendo il flusso di lavoro logico del progetto.

Fase 1: Setup Ambientale e Fondamenti di Riproducibilità (Giorni 1-2) Questa fase iniziale è la più critica, poiché stabilisce la base su cui si costruirà l'intero lavoro. L'obiettivo è creare un ambiente di lavoro organizzato, riproducibile e pronto per l'automazione.

- **1.1 Inizializzare il Repository Git:** Creare la cartella principale del progetto (es. `Flegrei\_Alert\_2026`) e inizializzare un nuovo repository Git con il comando `git init`. Successivamente, creare un repository vuoto sul servizio Git preferito (GitHub, GitLab, etc.) e collegarlo al repository locale.
- **1.2 Configurare la Struttura del Progetto:** Creare manualmente la struttura di cartelle e file delineata nella sezione sull'architettura del progetto: `data/raw`, `data/processed`, `scripts`, `notebook`, `reports/fig`, e i file `.gitignore`, `README.md`, `metadata.yaml`, `Dockerfile`, e `CHECKLIST.md`.
- **1.3 Creare il Dockerfile:** Scrivere il file `Dockerfile` che definisce l'ambiente di analisi. Questo include la scelta dell'immagine base (es. `rocker/tidyverse` per R), l'aggiunta di Python (opzionale ma utile), e l'installazione di tutti i pacchetti R e Python necessari per l'analisi (es. `survival`, `lme4`, `tidyverse`, `obsr`). Testare la build del container con il comando `docker build -t flegrei-alert .`.
- **1.4 Configurare `.gitignore`:** Modificare il file `.gitignore` per escludere tutti i file e le cartelle che non devono essere tracciati da Git, come `\_\_pycache\_\_`, `.Rhistory`, e, soprattutto, i file all'interno di `data/raw/` se sono di grandi dimensioni.
- **1.5 Scrivere `metadata.yaml`:** Compilare il file `metadata.yaml` con le informazioni generali del progetto (titolo, autore, licenza CC-BY-4.0) e iniziare a strutturarlo per accogliere i metadati dei singoli dataset man mano che verranno recuperati.

Fase 2: Acquisizione e Pre-elaborazione dei Dati (Giorni 2-3) Con l'ambiente pronto, si passa all'acquisizione automatizzata dei dati grezzi e alla loro pulizia preliminare.

- **2.1 Scrivere gli Script di Recupero Dati:** Sviluppare tre script principali nella cartella `scripts/`:
 - `download\_gnss.py`: Script Python per scaricare i dati GNSS dal Portale Open Data INGV 7.
 - `download\_seismic.py`: Script Python con `obsr` per interrogare l'API del portale INGV Earthquake List 14 e recuperare il catalogo per il 17-18 febbraio 2026.

- ``download_geochem.R``: Script R per recuperare i dati geochimici da Pisciarelli/Solfatara, che potrebbe richiedere un approccio personalizzato.
- **2.2 Eseguire gli Script di Recupero:** Eseguire i tre script per scaricare i dati grezzi e salvarli nella cartella ``data/raw/``.
- **2.3 Calcolare i Checksum:** Modificare gli script di recupero per calcolare automaticamente il checksum SHA-256 per ogni file scaricato e aggiornare il file ``metadata.yaml`` con questi valori.
- **2.4 Scrivere gli Script di Preprocessing:** Sviluppare script di preprocessing (es. ``preprocess_gnss.R``, ``preprocess_seismic.py``) che leggono i file da ``data/raw/``, puliscono i dati (es. rimozione di outlier GNSS tramite IQR [27](#)), calcolano le variabili ausiliarie (es. Interevent Time per i dati sismici) e salvano il dataset pulito e pronto all'analisi in ``data/processed/``.
- **2.5 Verificare i Dati Processati:** Esaminare manualmente i file CSV in ``data/processed/`` per assicurarsi che il preprocessing abbia funzionato come previsto.

Fase 3: Analisi Statistica Avanzata (Giorni 3-5) Questa è la fase di analisi propriamente detta, dove i dati processati vengono utilizzati per calcolare gli indicatori scientifici chiave.

- **3.1 Analisi Geodetica:** Eseguire l'analisi sulla serie temporale GNSS per calcolare il change-point (usando metodi come PELT e Bai-Perron) e per derivare l'indicatore di Critical Slowing Down (CSD) tramite il calcolo della rolling variance e dell'autocorrelazione al lag-1 [27](#).
- **3.2 Analisi Sismologica:** Applicare l'analisi di sopravvivenza (fit della distribuzione Weibull sugli IET) per valutare la tendenza sismica [27](#). Implementare un modello di Hawkes (ETAS) per confermare la presenza di auto-eccitazione e confrontare l'adeguatezza del modello con quella della distribuzione Weibull tramite criteri di informazione come l'AIC [27](#).
- **3.3 Analisi Geochimica:** Condurre test di cointegrazione (Engle-Granger e Johansen) per esplorare la relazione tra i dati geochimici ($\text{CO}_2/\text{H}_2\text{O}$) e la deformazione (componente verticale da GNSS) [27](#). Utilizzare il test di causalità di Granger per investigare la direzione dell'influenza tra le serie temporali [27](#).
- **3.4 Propagazione dell'Incertezza:** Dove appropriato, propagare l'incertezza attraverso i modelli (es. tramite simulazione Monte Carlo) per derivare intervalli di confidenza per le stime chiave, come le soglie di stress o i parametri dei modelli statistici.

Fase 4: Reporting e Visualizzazione (Giorno 6) L'obiettivo di questa fase è tradurre i risultati numerici in un racconto visivo e persuasivo, pronto per la Nota Tecnica.

- **4.1 Generare Grafici Finali:** Creare tutti i grafici essenziali (serie temporali, funzione di rischio, diagrammi a dispersione, etc.) e salvarli nella cartella `reports/fig/` in formato PNG ad alta risoluzione (300 dpi) [27](#).
- **4.2 Compilare il Report RMarkdown:** Aggiornare il file `notebook/report.Rmd` con i risultati finali, inserendo i grafici generati e redigendo le sezioni narrative che collegano i risultati alle ipotesi scientifiche.
- **4.3 Knit il Report in PDF:** Compilare il file `.Rmd` in un documento PDF (`Flegrei\_Alert\_2026.pdf`) usando la funzione `rmarkdown::render()`. Verificare attentamente il layout finale, le didascalie dei grafici e l'assenza di errori.

Fase 5: Revisione, Invio e Archiviazione (Giorno 7) L'ultima fase consiste in una revisione finale, la preparazione dell'invio e l'archiviazione permanente del lavoro.

- **5.1 Dry-run Completo:** Eseguire un "dry-run" completo della pipeline, partendo dalla costruzione del container Docker fino alla generazione del PDF finale, per assicurarsi che tutto funzioni come previsto.
- **5.2 Revisione Paritaria:** Condividere la bozza della Nota Tecnica e il repository con un collega esperto (preferibilmente un geodeta o un sismologo) per una revisione rapida e costruttiva.
- **5.3 Preparare l'Invio:** Compilare il corpo dell'email di invio, rivolto ai destinatari designati (es. Dott. De Martino, Dott. Di Vito, Dott.ssa Pappalardo), con un oggetto chiaro e un tono professionale e collaborativo [27](#).
- **5.4 Caricare su Zenodo:** Caricare l'intero repository Git su Zenodo per ottenere un DOI permanente, come discusso nella sezione sulla riproducibilità.
- **5.5 Invio e Follow-up:** Allegare alla mail il PDF della Nota Tecnica, il `DataPackage.zip` (contenente i dati processati e i metadati), e il link a Zenodo. Programmare un follow-up email dopo 5 giorni lavorativi in caso di mancato riscontro.

Seguendo questa roadmap strutturata, è possibile affrontare il complesso compito di analisi dei dati con un alto grado di ordine, efficienza e scientificità, massimizzando le probabilità di successo nella consegna di un prodotto di alta qualità all'INGV-Osservatorio Vesuviano.

Riferimento

1. Long – term variations of the Campi Flegrei, Italy, volcanic system as ... <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2008JB006258>
2. (PDF) Temperature and pressure gas geoindicators at the Solfatara ... https://www.researchgate.net/publication/267828090_Temperature_and_pressure_gas_geoindicators_at_the_Solfatara_fumarole_s_Campi_Flegrei
3. Monitoring diffuse volcanic degassing during volcanic unrests - Nature <https://www.nature.com/articles/s41598-017-06941-2>
4. Turbulent diffusion and volcanic gas dispersion in the atmospheric ... <https://link.springer.com/content/pdf/10.1186/s40623-025-02272-z.pdf>
5. MEDiterranean Supersite Volcanoes | FP7 - CORDIS <https://cordis.europa.eu/project/id/308665/reporting>
6. Caldera unrest driven by CO₂-induced drying of the deep ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC5974283/>
7. il Portale dei Dati Aperti dell'INGV – INGVterremoti <https://ingvterremoti.com/2020/11/18/il-portale-dei-dati-aperti-dellingv/>
8. La sorveglianza geochimica dei vulcani campani - INGVvulcani <https://ingvvulcani.com/2020/12/21/la-sorveglianza-geochimica-dei-vulcani-campani/>
9. Il Sistema di Monitoraggio multiparametrico dell'INGV-Osservatorio ... <https://ingvvulcani.com/2025/09/24/il-sistema-di-monitoraggio-multiparametrico-dellingv-osservatorio-vesuviano-sui-vulcani-campani/>
10. [PDF] GLOBAL MONITORING FOR SECURITY AND STABILITY (GMOSS) <https://publications.jrc.ec.europa.eu/repository/bitstream/JRC41424/eur%2023033%20en.pdf>
11. Mineral Resources for the Ceramic Industry: Survey of Feldspathic ... <https://www.mdpi.com/2075-163X/15/1/87>
12. (PDF) Lake Ohrid's tephrochronological dataset reveals 1.36 Ma of ... https://www.researchgate.net/publication/354329968_Lake_Ohrid's_tephrochronological_dataset_reveals_136_Ma_of_Mediterranean_explosive_volcanic_activity
13. SISMIKO: INGV operational task force for rapid deployment of ... <https://www.frontiersin.org/journals/earth-science/articles/10.3389/feart.2023.1146579/full>

14. The SISMO Monitoring Network and Insights into the 2024 Seismic ... <https://www.mdpi.com/2076-3263/15/11/436>
15. [PDF] Environmental-Software-Systems-Volume-7-Second-Edition.pdf https://www.researchgate.net/profile/Ralf-Denzer-2/publication/269166795_Environmental_Software_Systems_Volume_7_Second_Edition/links/54847f450cf283750c370758/Environmental-Software-Systems-Volume-7-Second-Edition.pdf
16. Insight Into Campi Flegrei Caldera Unrest Through Seismic Tremor ... <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2019GC008610>
17. Single-station analysis of Campi Flegrei (Italy) seismic signals using ... <https://www.nature.com/articles/s41598-026-38257-5>
18. Space and time distribution of seismic source energy at Campi ... <https://www.sciencedirect.com/science/article/pii/S003192012400116X>
19. Parameters and results. | Download Table - ResearchGate https://www.researchgate.net/figure/Parameters-and-results_tbl2_330456601
20. Assessing the adoption of the FAIR principles in Italian ... <https://www.sciencedirect.com/science/article/pii/S2666389925002685>
21. Metadata and Semantic Research - Springer Link <https://link.springer.com/content/pdf/10.1007/978-3-031-81974-2.pdf>
22. Surface Temperature Multiscale Monitoring by Thermal Infrared ... <https://www.mdpi.com/2072-4292/11/9/1007>
23. Tracking the 2007–2023 magma-driven unrest at Campi Flegrei ... <https://www.nature.com/articles/s43247-024-01665-4>
24. First evidence of a geodetic anomaly in the Campi Flegrei caldera ... <https://www.sciencedirect.com/science/article/pii/S156984322400414X>
25. ASI pilot project to support the monitoring of volcanic risk in Italy by ... <https://ieeexplore.ieee.org/document/4740367/>
26. Surface Temperature Multiscale Monitoring by Thermal Infrared ... https://www.researchgate.net/publication/332734086_Surface_Temperature_Multiscale_Monitoring_by_Thermal_Infrared_Satellite_and_Ground_Images_at_Campi_Flegrei_Volcanic_Area_Italy
27. The recurrence of geophysical manifestations at the Campi Flegrei ... <https://www.science.org/doi/10.1126/sciadv.adt2067>
28. Remote Sensing Applications for Geological Mapping in the ... - MDPI <https://www.mdpi.com/2076-3263/15/11/425>
29. (PDF) Remote Sensing Applications for Geological Mapping in the ... <https://www.researchgate.net/publication/>

395127841_Remote_Sensing_Applications_for_Geological_Mapping_in_the_Mediterranean_Region_A_Review

30. Appl. Sci., Volume 16, Issue 1 (January-1 2026) – 561 articles <https://www.mdpi.com/2076-3417/16/1>
31. Appl. Sci., Volume 15, Issue 6 (March-2 2025) – 543 articles - MDPI <https://www.mdpi.com/2076-3417/15/6>
32. dominantly silicic volcanism associated with the Taupo Rift, New ... https://www.researchgate.net/publication/223909349_Volcanic_and_structural_evolution_of_the_Okataina_Volcanic_Centre_dominantly_silicic_volcanism_associated_with_the_Taupo_Rift_New_Zealand
33. [PDF] Rapport quadriennal 2007 - 2011 | HAL https://hal.science/hal-04787039v1/file/CNFGG_RapQuad_UGGI2011.pdf
34. (PDF) New Insights on Ground Deformation at Campi Flegrei ... https://www.researchgate.net/publication/368999190_New_Insights_on_Ground_Deformation_at_Campi_Flegrei_Caldera_Inferred_From_Kinematics_and_Dynamics_Investigation_of_Borehole_Tilt
35. (PDF) 120 YEARS OF ITALIAN AND VESUVIUS HISTORY IN THE ... https://www.academia.edu/11521184/120_YEARS_OF_ITALIAN_AND_VESUVIUS_HISTORY_IN_THE_LAVA_MEDALS_COLLECTION_OF_THE_OSSERVATORIO_VESUVIANO
36. Surface uplift and time-dependent seismic hazard due to fluid ... https://www.researchgate.net/publication/308576948_Surface_uplift_and_time-dependent_seismic_hazard_due_to_fluid_injection_in_eastern_Texas
37. Volcanic hazards in the Aegean area, relative risk evaluation ... https://www.researchgate.net/publication/248597295_Volcanic_hazards_in_the_Aegean_area_relative_risk_evaluation_monitoring_and_present_state_of_the_active_volcanic_centers
38. AGU Friday Daily Newspaper | PDF | Particulates - Scribd <https://www.scribd.com/document/253002812/AGU-Friday-Daily-Newspaper>
39. The recurrence of geophysical manifestations at the Campi Flegrei ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12047431/>